

Bootstrap

Departamento de Matemáticas. Uniandes.

Semestre 2026-I.

1 Principio Plug in

La simulación Monte Carlo consiste en producir muchas veces, muestras de datos, cuya distribución conocemos, y estudiar la distribución de un estadístico de interés. Por ejemplo, en un problema de colas, es muy posible que conozcamos (o podamos estimar con bastante precisión) la tasa a la cual se incorporan individuos a un proceso de colas (“atención al cliente”) y que también conozcamos la distribución del tiempo de atención que requiere un cliente. Entonces podemos generar muchas veces el proceso de llegadas de clientes durante cinco horas y “observar” la variable $T =$ “tiempo que el cliente pasa en cola antes de ser atendido”, por ejemplo.

En el contexto de ENP, muchas veces tenemos datos a los cuales no queremos asignar una distribución particular y, al mismo tiempo, quisiéramos hacer un Monte Carlo, para estudiar el comportamiento de cierto estadístico de interés. Para este problema (general) surgió la propuesta de remuestreo (bootstrap) de Bradley Efron en los años 70. El remuestreo tiene un basamento matemático en el teorema de Glivenko-Cantelli, cuya versión básica dice:

Theorem 1 *Sea $X_1, X_2, \dots$ muestra i.i.d. de una distribución F . Sea $F_n(t)$ la versión empírica de F , es decir $F_n(t) = \#\{i \leq n : X_i \leq t\}/n$, la proporción de datos muestrales menores o iguales a t . Entonces*

$$\sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \rightarrow 0, \text{ c.p. 1, cuando } n \rightarrow \infty.$$

Este teorema nos dice que la distribución empírica converge a la distribución de los datos, en una norma tan exigente como $\|\cdot\|_\infty$, por lo que la propuesta es hacer B muestras provenientes de F_n y usarlas como si fueran de F . Un momento de reflexión nos convencerá de que una muestra i.i.d. de tamaño n de F_n es una lista de (los mismos) datos, $X_1^*, X_2^*, \dots, X_n^*$ tomados de la muestra original, al azar y con remplazo

La implementación del bootstrap se explica mejor en el contexto de estimadores tipo ‘‘plug in’’ y en el contexto de hallar un intervalo de confianza $1 - \alpha$ para el parámetro buscado. Sea $\theta = \theta(F)$ un parámetro asociado a la distribución F . θ puede ser un cuantil, un momento, un coeficiente de asimetría, etc. Decimos que un estadístico que estima $\theta(F)$ es plug in cuando es el mismo parámetro evaluado en la empírica, $\theta(F_n)$. Por ejemplo $\bar{X}$ es plug in como estimador de μ , pero s^2 , aunque insesgado, no es plug in como estimador de σ^2 .

Al generar $B = 10,000$ muestras de tamaño n de F_n , llamamos $\mathbb{X}^b = (X_1^{*,b}, X_2^{*,b}, \dots, X_n^{*,b})$ a la b -ésima muestra bootstrap. Tenemos B valores $\theta^b = \theta(\mathbb{X}^b)$. Con esa lista construimos otra $\{\theta^b - \theta(F_n) : b \in 1, \dots, B\}$, y estimamos cuantiles tales que

$$\Pr(\theta^b - \theta(F_n) \in (c_1, c_2)) \approx 1 - \alpha \quad (1)$$

Ahora bien, basados en la cercanía entre F y F_n , postulamos (existen teoremas que dicen) que

$$\theta^b - \theta(F_n) \stackrel{(d)}{\approx} \theta(F_n) - \theta(F)$$

y por lo tanto, (1) se convierte en

$$\Pr(c_1 < \theta(F_n) - \theta(F) < c_2) \approx 1 - \alpha \quad (2)$$

de donde $\theta(F_n) - c_2 < \theta(F) < \theta(F_n) - c_1$ es nuestro intervalo de confianza bootstrap para $\theta(F)$. Note el cambio de función de c_1 y c_2 en el IC bootstrap.

2 Estimación de sesgo y varianza

Sea ahora T un estimador de $\theta(F)$. Su sesgo, $\text{Bias}(T|F)$ se define como

$$\text{Bias}(T|F) = \mathbb{E}_F(T(\mathbb{X})) - \theta(F)$$

y el correspondiente estimador bootstrap es

$$\hat{\text{Bias}}(T|F) = \frac{1}{B} \sum_{b=1}^B T(\mathbb{X}^b) - \theta(F_n),$$

donde cada $\mathbb{X}^b$ es una muestra, de tamaño n , de la distribución F_n .

Para estimar la varianza o la desviación estándar de T cuando se aplica a datos provenientes de F , $\text{sd}(T|F)$, recordamos que la desviación estándar es

$$\text{sd}(T|F)^2 = \mathbb{E}_F((T(\mathbb{X})) - (\theta(F) + \text{Bias}(T|F)))^2 \quad (3)$$

donde estamos usando que $(\theta(F) + \text{Bias}(T|F) = \mathbb{E}_F(T(\mathbb{X}))$. Y el estimador de $\text{sd}(T|F)$ será, sencillamente

$$\text{sd}(T|F) = \sqrt{\frac{1}{B} \sum_{b=1}^B (T(\mathbb{X}^b) - \bar{T}^*)^2}, \quad (4)$$

siendo $\bar{T}^*$ el promedio de los valores de T calculados en las muestras $\mathbb{X}^b$.

Puede pasar que, para algún estadístico, T , se tenga conocimiento de normalidad asintótica, como ocurre en el caso del coeficiente de correlación. Tenemos entonces

$$\mathcal{L}(T|F) \stackrel{(d)}{\approx} N(\theta(F) + \text{Bias}(T|F), \text{sd}(T|F)^2) \quad (5)$$

y por tanto, habiendo estimado el sesgo y la desviación estándar como se indicó arriba, tendremos

$$\Pr(T \leq t|F) \approx \Phi\left(\frac{t - (\theta(F) + \hat{\text{Bias}}(T|F))}{\text{sd}(T|F)}\right) \quad (6)$$

siendo Φ la f.d.a. $N(0,1)$. De esta última aproximación podemos extraer un intervalo de confianza para $\theta(F)$, que será generalmente más pequeño que el obtenido solo por cuantiles bootstrap, gracias a la hipótesis de normalidad (ver la sección 2.1.2 de [1]).

3 Un ejemplo

Sea $(X_1, Y_1), \dots, (X_n, Y_n)$ una muestra i.i.d. de pares de números reales, provenientes de una ley de probabilidad P en $\mathbb{R}^2$. Para medir la dependencia entre las coordenadas X y Y usamos el coeficiente de correlación de Pearson

$$\rho_n = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

Con esta fórmula para la correlación estimada sobre una muestra finita, ρ_n es un estadístico plug in. En nuestro ejemplo, para una muestra de una Normal Bivariada con matriz de covarianza

$$C = \begin{pmatrix} 1 & -0.8436 \\ -0.8436 & 1 \end{pmatrix},$$

consideramos los IC bootstrap dados por (2), (6) y un tercero basado en la transformación

$$\Psi : \rho_n \rightarrow 0.5 \ln \left(\frac{1 + \rho_n}{1 - \rho_n} \right).$$

Esta transformación, propuesta por Fisher, acelera la convergencia de ρ_n a la Normal. En el script de R adjunto se puede ver la implementación de los tres métodos de estimación de los IC bootstrap.

4 El t-remuestreo

La idea de trabajar con la variable estandarizada, $(T - \mathbb{E}(T|F))/sd(T|F)$ usando cuantiles normales (o t de student) deja de ser apropiada cuando la distribución de T para los datos subyacentes o para el tamaño muestral, se aleja de la normalidad. El t -remuestreo (bootstrap t) permite seguir usando la variable “studentizada” a través de dos cambios en el procedimiento bootstrap.

- (i) En lugar de un solo valor para $sd(T|F)$ (extraído de las muestras bootstrap), a través de un segundo nivel de remuestreo, se busca un estimador específico para $sd(T|\mathbb{X}^b)$ usando muestras bootstrap obtenidas partiendo de la muestra $\mathbb{X}^b$ como la “muestra original”. Entonces, los cocientes studentizados son

$$Z^{*,b} = \frac{T^{*,b} - T(F_n)}{sd(T|\mathbb{X}^b)} \quad (7)$$

- (ii) Los cuantiles usados para despejar el IC no provienen de la distribución normal o la t de Student, sino que son cuantiles muestrales obtenidos de la muestra de los $Z^{*,b}$. Es decir, los valores de los $Z^{*,b}$ se usan para crear la “tabla” de la distribución “ t de student” apropiada para los datos considerados.

El script anexo llamado *Bootstrap t* incluye detalles de implementación, en el caso específico de obtener un IC para la media de una variable exponencial, muy alejada

de la simetría de la normal. La teoría disponible para el bootstrap t , desarrollada por Peter Hall en [3], indica que, en cuanto a la estimación de probabilidades, el bootstrap básico tiene un error que es $O_{Pr}(1/\sqrt{n})$, mientras que el bootstrap t , reduce dicho error a $O_{Pr}(1/n)$. Esto justifica el esfuerzo computacional adicional.

5 Remuestreo para regresión

Cuando consideramos el modelo lineal múltiple

$$Y_i = \beta_0 + x_{i,1}\beta_1 + \cdots + x_{i,k}\beta_k + \epsilon_i \quad (8)$$

la forma del estimador del vector de parámetros, solo depende de la elección de *mínimos cuadrados* como el método de estimación, pero para obtener intervalos de confianza para los β_j y realizar pruebas de hipótesis sobre los coeficientes, se suele suponer normalidad de los errores.

¿Como proceder para llegar a I.C. sobre todo el vector β o algunas de sus componentes, cuando no queremos suponer normalidad del vector ϵ es normal?

5.1 Remuestro de los residuos

Estamos en el caso

$$\mathbb{E}(\epsilon) = 0, \quad \text{Cov}(\epsilon) = \sigma^2 I,$$

es decir, donde Z tiene coordenadas que tienen varianza común y no tienen correlación. Sea β el vector de coeficientes, y $\hat{\beta}$ su estimador. Sea Y el vector de los Y_i . Sea $\mathbb{X}$ la matriz $n \times (k+1)$ con el vector de predictores $(1, x_{i,1}, \dots, x_{i,k})$ en la i -ésima fila. Suponemos que $\mathbb{X}$ tiene rango $k+1$.

Planteando *mínimos cuadrados* obtenemos

$$\hat{\beta} = (\mathbb{X}^t \mathbb{X})^{-1} \mathbb{X}^t Y$$

El vector $\hat{Y} = \mathbb{X} \hat{\beta}$ es el vector de respuestas predicho por el modelo ajustado (al hallar $\hat{\beta}$). Se puede definir $\hat{\beta}$ diciendo que $\mathbb{X} \hat{\beta} = \hat{Y}$ es el vector más cercano a Y en el espacio generado por las columnas de $\mathbb{X}$. Tenemos que

$$\hat{Y} = \mathbb{X}(\mathbb{X}^t \mathbb{X})^{-1} \mathbb{X}^t Y =: HY$$

Observamos que $H = \mathbb{X}(\mathbb{X}^t\mathbb{X})^{-1}\mathbb{X}^t$ es autoadjunta, $H' = H$ y $H^2 = H$ por lo que H es una matriz de proyección. De hecho, H es la matriz de proyección sobre el espacio generado por las columnas de $\mathbb{X}$. El vector de residuales

$$e = Y - \hat{Y} = (I - H)Y$$

es el vector de errores cometidos por el modelo ajustado y cumple

$$\text{Cov}(e) = (I - H)\text{Cov}(Y)(I - H) = \sigma^2(I - H)(I - H) = \sigma^2(I - H) \quad (9)$$

Por otro lado, en el modelo lineal múltiple, el estimador insesgado de σ^2 es $s^2 = \frac{1}{n-k} \sum_i (Y_i - \hat{Y}_i)^2$ y, por lo tanto, el estimador de $\text{Cov}(e) = s^2(I - H)$. Se concluye que los errores en los distintos $\hat{Y}_i$ no son homocedásticos. La varianza estimada de e_j es $s^2(1 - h_j)$, siendo h_j el elemento de H en la posición (j, j) . Para cumplir con el modelo (8), queremos que nuestros errores (para los distintos Y_i) sean homocedásticos, por eso definimos $r_i = e_i / \sqrt{1 + h_i}$.

El primer esquema de remuestreo es el siguiente: Para cada j , sea $\underline{X}_j$ la j -ésima fila de $\mathbb{X}$ (el vector de covariables para la variable Y_j). Hacemos $X_j^{*,b} = \underline{X}_j$ es decir, las covariables de las muestras bootstrap son las mismas de la muestra original, sin remuestreo. Ahora el $\epsilon_i^{*,b} = r_i^{*,b}$ siendo $r_i^{*,b}$ muestreado, al azar y con remplazo del conjunto $\{r_1, \dots, r_n\}$ de residuos estandarizados.

En breve: en el primer esquema de remuestreo para regresión, las covariables no se tocan, ni siquiera se cambian de orden, mientras que los errores se muestrean al azar y con remplazo de los residuales estandarizados.

5.2 Remuestreo de pares

El MLM aparece en muchos contextos de aplicación. En algunos la matriz de diseño es, efectivamente, diseñada, para explorar el espacio disponible y buscar algún óptimo de la variable respuesta. En esos casos, es recomendable usar el esquema de remuestreo de la subsección anterior: no alterar los valores de X_i . Pero también existen experimentos en los que los valores del par (X_i, Y_i) son ambos aleatorios según alguna distribución P en $\mathbb{R}^k \times \mathbb{R}$. En este caso el esquema más apropiado puede ser el de tratar los pares como puntos aleatorios y que la muestra bootstrap consista en elegir índices del 1 al n al azar, con remplazo, del uno al n , $i_1^{*,b}, i_2^{*,b}, \dots, i_n^{*,b}$ y, omitiendo la “b” la muestra bootstrap será $(X_1^*, Y_1^*), \dots, (X_n^*, Y_n^*)$. Sobre esta muestra se calcula el parámetro $\hat{\beta}^{*,b}$.

References

- [1] Davison, A. C. and Hinkley, D. V. (1997) *Bootstrap Methods and their Application*, Cambridge University Press.
- [2] Efron, B. and Tibshirani, R. J. (1993) *An Introduction to the Bootstrap*, Chapman and Hall. London, New York.
- [3] Hall, P. (1988) Theoretical comparison of bootstrap confidence intervals. (with discussion.) *Ann. Statist.* **16**, pp. 927-953.