

Proyecto II, 2026-10

Comparando métodos de bondad de ajuste a simetría, basados en el bootstrap.

Un estadístico de remuestreo tipo Kolmogorov-Smirnov

En el ámbito univariado, la definición de simetría, en θ , de una distribución, es única: $1 - F(\theta + t) = F(\theta - t)$, para todo t . También se puede escribir como

$$P(A) = P(2\theta - A), \forall A \text{ medible.}$$

Si una distribución empírica es simétrica en θ , se tiene que $F_n = sF_n(\theta)$, siendo

$$sF_n(\theta) = \frac{1}{2} \sum_i (\delta_{X_i} + \delta_{2\theta - X_i}) \quad (1)$$

Schuster and Barker, [4], propusieron usar el siguiente estadístico para evaluar la H_0 de simetría (univariada) contra la alternativa H_a : la distribución no es simétrica.

$$T_n = \sqrt{n} \|F_n - sF_n(\tilde{\theta})\|_\infty \quad (2)$$

para $\tilde{\theta}$ un estimador del centro de simetría. La motivación es la siguiente: $sF_n(\tilde{\theta})$ es la distribución simétrica discreta más cercana a F_n . Si la F es simétrica, F_n también lo será, aproximadamente, y no estará lejos de su simetrización. Si F no es simétrica, $sF_n(\tilde{\theta})$ tendrá que cambiar mucho, con respecto a F , a la F_n .

Vamos a considerar tres posibilidades para el estimador de centro de simetría.

- $\tilde{\theta} = \arg \min (T_n)$: el minimizador de la norma supremo de la fórmula (2). Es decir, se varía $\tilde{\theta}$ en (2) y se elige el parámetro que produzca el mínimo T_n .
- $\tilde{\theta} = \text{median}(X_1, \dots, X_n)$
- $\tilde{\theta} = \overline{X}_\alpha(X_1, \dots, X_n)$, una media afeitada de los datos.

Ahora bien, la distribución de T_n , definida arriba, depende de la F que produce los datos. Por esto, Schuster and Barker proponen el uso del bootstrap para obtener cuantiles de

T_n bajo la hipótesis nula, generando los datos de $sF_n(\tilde{\theta})$, la distribución simétrica más cercana a F_n . Se generan, digamos, $B = 500$ muestras $X_1^*(b), \dots, X_n^*(b)$, y para cada una se calcula

$$T_n^*(b) = \sqrt{n} \|F_n^* - sF_n^*(\tilde{\theta}^*)\|_\infty \quad (3)$$

siendo $\tilde{\theta}^*$ estimador del punto de simetría obtenido de la muestra bootstrap. Comparando el valor de T_n obtenido para la muestra original con la lista de los $T_n^*(b)$, se puede obtener un p -valor aproximado para T_n . El trabajo de Arcones y Giné, [1], se encarga de justificar la validez de este bootstrap. No se pide que Ud siga el argumento de esa demostración, pero si que puedan enunciar cual es el resultado teórico obtenido en [1].

La función característica empírica

Para una variable aleatoria, X , a valores reales, la función característica se define como

$$c(t) = \varphi(t) = \mathbb{E}(e^{itX}) = \mathbb{E}(\cos(tX)) + i\mathbb{E}(\sin(tX)).$$

siendo $i = \sqrt{-1}$. Esta función facilita la demostración del TLC con las hipótesis justas, sin tener que suponer la existencia de muchos momentos de la X . Dada una muestra $X_1, \dots, X_n$, la versión empírica de $c(t)$ es

$$c_n(t) = \frac{1}{n} \sum_{j \leq n} e^{itX_j} = \frac{1}{n} \sum_{j \leq n} \cos tX_j + \frac{i}{n} \sum_{j \leq n} \sin tX_j. \quad (4)$$

Una propiedad relevante de la f.c. es que $c(t)$ es real (su parte imaginaria es cero) si, y solo si, la distribución de la variable aleatoria X , correspondiente, es simétrica en 0. Se sigue que $X \sim \text{sim}(\theta)$ si, y solo si,

$$c(t) = e^{it\theta} c_0(t), \quad \text{con } c_0 \text{ real.}$$

Para una f.c. $c(t)$, se considera una versión simétrica, $c_s(t) = \|c(t)\|$, que tiene la misma norma de $c(t)$ (y es, claramente, simétrica). Dada una función característica empírica (f.c.e.), podemos medir cuan cerca está de corresponder a una variable simétrica en θ por el valor de una integral como

$$S_n = \int_{-\infty}^{\infty} \|c_n(t)e^{-it\theta} - c_s(t)\|^q w(t) dt \quad (5)$$

con $q = 1$ o 2 , siendo $w(t)$ una densidad simétrica y $c_s(t) = c_s^\theta(t) = \|c_n(t)e^{-it\theta}\| = \|c_n(t)\|$, pues el factor $e^{-it\theta}$ no cambia la norma. Consideramos tres maneras de estimar el centro de simetría, asociado a una muestra, $X_1, \dots, X_n$ con f.c.e. $c_n(t)$:

- $\hat{\theta} = \arg \min (S_n)$: el minimizador de la integral de penalización (5). Se toman valores de θ en un intervalo J . Para cada $\theta \in J$, se calcula la integral S_n de (5) y se selecciona el θ que minimice el S_n resultante.
- $\hat{\theta} = \text{median}(X_1, \dots, X_n)$
- $\hat{\theta} = \overline{X}_\alpha(X_1, \dots, X_n)$, una media afeitada de los datos.

Para el $\hat{\theta}$ elegido, guardamos el valor del estadístico S_n , y para determinar su p -valor, usamos un procedimiento bootstrap similar al de la sección anterior: Para $b : 1 \rightarrow B$

- Producir muestra $X_1^*(b), \dots, X_n^*(b)$ de $sF_n(\hat{\theta})$ (definición de sF_n en la sección anterior).
- Estimar el punto de simetría de la muestra bootstrap, obteniendo un $\hat{\theta}^*(b)$.
- Calcular la correspondiente integral de penalización $S_n^*(b)$ aplicando la fórmula (5) a la muestra y estimador bootstrap.

De los B valores de $S_n^*(b)$ extraiga un p -valor para el S_n observado inicialmente.

El objetivo es implementar y evaluar el desempeño de ambos tests bootstrap de simetría. Para ello considere, bajo H_0 , la distribución uniforme (en un intervalo no centrado en cero) y la distribución de Cauchy, con parámetro de localización distinto de cero. Para las distribuciones asimétricas, para medir potencia, puede usar una Gamma, una Weibull o una Pareto.

Pruebe distintas posibilidades para $w(t)$. En la definición de S_n , considere las dos posibilidades para q .

Consideré distintos tamaños muestrales. Si para algún valor de n , todas las potencias son muy altas, disminuya el n . Si ningún test tiene potencia, incremente el n .

Incluya algunas discusiones teóricas, por ejemplo, porque X es simétrica cuando $c(t)$ es real?. Incluya en su discusión la complejidad computacional, junto con la potencia y el cumplimiento del nivel.

El proyecto está pensado para ser realizado en equipos de 2 personas. Puede también trabajar individualmente si lo prefiere. En casos excepcionales, previa discusión conmigo, pudiera considerarse un equipo de tres personas.

Su informe debe incluir una breve introducción al problema, el código de los programas escritos suficientemente explicado y comentado, descripción y análisis de resultados y conclusiones.

Valor del proyecto: 20 pts. Subir el informe al enlace que se creará en Actividades de BN antes del miércoles 27 de mayo a las 11 pm.

References

- [1] Arcones, M. A. & Gine, E. (1991) Some Bootstrap Tests of Symmetry for Univariate Continuous Distributions. *The Annals of Statistics*, **19**, No 3, pp 1496 – 1511.
- [2] Csörgő, S. & Heathcote, C. R. (1987) Testing for symmetry, *Biometrika*, **74**, Issue 1, Pages 177-184.
- [3] Feuerverger, A. and Mureika, R. A. (1977). The Empirical Characteristic Function and Its Applications. *The Annals of Statistics*, **5**(1), 88-97.
- [4] Schuster, E. F. & Barker, R. C. (1987). Using the bootstrap in testing symmetry versus asymmetry. *Communications in Statistics - Simulation and Computation*, **16**(1), 69-84.