

Introducción

La estadística no paramétrica estudia métodos de inferencia que requieren menos supuestos sobre la distribución de los datos que los procedimientos paramétricos. En este proyecto se realiza un estudio de simulación orientado a la comparación de dos muestras bajo múltiples escenarios, con el objetivo de evaluar el desempeño de distintos métodos en términos de su capacidad para detectar diferencias entre distribuciones. Estudiamos la potencia de cada procedimiento frente a cambios en la localización, la presencia de valores atípicos y variaciones en la forma de las distribuciones.

1. Marco teórico

A continuación se describen los estadísticos empleados para comparar dos muestras independientes. Estos incluyen tanto estadísticos paramétricos como no paramétricos, y permiten evaluar diferencias entre distribuciones desde distintos enfoques, como la comparación de medias, de rangos o de estimadores robustos de localización.

1.1. t-Student (t)

El clásico estadístico basado en la distribución t de Student, descrito por ejemplo en [6], que se emplea para comparar la media de dos muestras independientes, asumiendo varianzas poblacionales idénticas y finitas. Sean $X_1, \dots, X_m \sim F_X$ y $Y_1, \dots, Y_n \sim F_Y$ muestras aleatorias i.i.d. con medias μ_X y μ_Y , y varianza común σ^2 .

Se plantean las hipótesis $H_0 : \mu_X - \mu_Y = 0$ vs $H_1 : \mu_X - \mu_Y \neq 0$, y se considera el estadístico dado por:

$$t = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{m} + \frac{1}{n}}}$$

donde S_p^2 es la varianza combinada definida como:

$$S_p^2 = \frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}$$

Bajo los supuestos de normalidad e igualdad de varianzas, el estadístico t sigue exactamente una distribución t de Student con $m+n-2$ grados de libertad, a partir de la cual se calcula el p-valor bilateral.

1.2. t de Welch

El test t de Welch es la alternativa robusta para dos muestras independientes cuando se vulnera el supuesto de homocedasticidad ($\sigma_X^2 \neq \sigma_Y^2$). Esta prueba, propuesta por Welch en 1947 [7]. El estadístico está dado por:

$$t_W = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_X^2}{m} + \frac{S_Y^2}{n}}}$$

Bajo supuestos de independencia y normalidad, t_W se aproxima a una distribución t de Student donde los grados de libertad ν se estiman mediante la ecuación de Welch-Satterthwaite [1]. En la implementación computacional, el p-valor se calcula utilizando esta aproximación con los grados de libertad ajustados.

1.3. Wilcoxon (W)

El test de rangos de Wilcoxon [2] evalúa la hipótesis nula de igualdad de distribuciones ($H_0 : F_X = F_Y$). Para que la prueba sea estrictamente libre de distribución, se asume que F_X y F_Y son distribuciones **absolutamente continuas**, garantizando teóricamente la ausencia de empates.

Sea $Z_1, \dots, Z_{m+n}$ la muestra combinada y $R(X_i)$ el rango de X_i en dicha muestra. El estadístico se define como:

$$W = \sum_{i=1}^m R(X_i)$$

Este test es equivalente al estadístico U de Mann-Whitney, el cual cuenta el número de excedencias de Y sobre X :

$$U = \sum_{i=1}^m \sum_{j=1}^n \mathbf{1}(X_i < Y_j)$$

Relacionados mediante la identidad $U = W - \frac{m(m+1)}{2}$. Bajo H_0 se tiene:

$$\mathbb{E}[U] = \frac{mn}{2}, \quad \text{Var}(U) = \frac{mn(m+n+1)}{12}$$

Asintóticamente, si $m, n \rightarrow \infty$ de manera que la proporción $\frac{m}{m+n} \rightarrow \lambda \in (0, 1)$, el estadístico estandarizado converge a una normal estándar:

$$Z = \frac{U - \mathbb{E}[U]}{\sqrt{\text{Var}(U)}} \xrightarrow{d} N(0, 1)$$

La cota de Berry-Esseen asegura que el error de esta aproximación es de orden $O(N^{-1/2})$ [4] donde $N = M + n$, lo que justifica el uso de la aproximación normal para los tamaños muestrales de este estudio, permitiendo aislar el desempeño de la prueba sin interferencia del error de aproximación.

1.4. Intervalo de confianza Hodges-Lehmann (HL)

Este método asume explícitamente el **modelo de locación continuo**, donde $F_Y(x) = F_X(x - \Delta)$ para algún parámetro de desplazamiento $\Delta \in \mathbb{R}$. Bajo este modelo, el estimador puntual de Hodges-Lehmann [2] se define

como la mediana de las $m \times n$ diferencias de Walsh:

$$\hat{\Delta}_{HL} = \text{median}\{Y_j - X_i : i = 1, \dots, m, j = 1, \dots, n\}$$

El intervalo de confianza al $1 - \alpha$ para el parámetro poblacional Δ se construye invirtiendo la prueba de Wilcoxon-Mann-Whitney. Ordenando las mn diferencias como $D_{(1)} \leq \dots \leq D_{(mn)}$, el intervalo está dado por:

$$[D_{(k)}, D_{(mn-k+1)}]$$

donde el índice k corresponde al cuantil $\alpha/2$ de la distribución nula exacta del estadístico U .

1.5. Test condicional de permutación (P)

El test condicional de permutación [2] evalúa $H_0 : F_X = F_Y$ basándose en el principio de **intercambiabilidad**. Si la hipótesis nula es cierta, la asignación de las $m + n$ etiquetas a los datos observados es puramente aleatoria y equiprobable.

Se emplearon los siguientes estadísticos de contraste $T(X, Y)$: diferencia de medias; $\bar{X} - \bar{Y}$, diferencia de medianas; $\text{median}(X) - \text{median}(Y)$ y diferencia de medias recortadas; $\bar{X}_\epsilon - \bar{Y}_\epsilon$

El p-valor es la proporción de permutaciones espaciales cuyo $|T_{perm}|$ supera o iguala a $|T_{obs}|$. Cabe advertir que, si existe heterocedasticidad o diferencias en la forma de las colas, las muestras dejan de ser intercambiables y el test pierde su propiedad de nivel exacto, inflando el error Tipo I al rechazar H_0 no por diferencias en localización, sino por pérdida de intercambiabilidad general.

1.6. Kolmogorov-Smirnov (KS)

El test de Kolmogorov-Smirnov para dos muestras evalúa la hipótesis nula $H_0 : F_X = F_Y$ donde $X_1, \dots, X_m \sim F_X$ y $Y_1, \dots, Y_n \sim F_Y$ dos muestras aleatorias independientes absolutamente continuas. Bajo estas condiciones, el estadístico de Kolmogorov es libre de distribución bajo la hipótesis nula, el cual se define mediante

$$D_{m,n} = \sup_{x \in \mathbb{R}} |F_{X,m}(x) - F_{Y,n}(x)|$$

donde $F_{X,m}(x)$ y $F_{Y,n}(x)$ son las funciones de distribución empíricas de cada muestra.

Para tamaños muestrales pequeños, la distribución de $D_{m,n}$ bajo H_0 se obtiene mediante combinatoria. Sin embargo, para muestras grandes, el cálculo se vuelve computacionalmente ineficiente. En su lugar, se emplea la distribución asintótica del estadístico escalado. Según los resultados clásicos descritos por ejemplo en Shao [5], para tamaños m y n grandes, bajo H_0 la probabilidad acumulada asintótica está dada por:

$$\lim_{m,n \rightarrow \infty} P\left(\sqrt{\frac{mn}{m+n}} D_{m,n} \leq t\right) = \sum_{j=-\infty}^{\infty} (-1)^j e^{-2j^2 t^2}, \quad t > 0.$$

2. Metodología

En esta sección se detalla el diseño experimental utilizado para comparar el desempeño de los estadísticos de contraste descritos en la Sección 1. El estudio se llevó a cabo mediante simulación Monte Carlo, evaluando la robustez y la potencia de cada método a través de múltiples escenarios distribucionales con $R = 500$ réplicas independientes por escenario.

En cada experimento, la comparación se fundamenta en pares de muestras independientes:

$$X_1, \dots, X_m \sim F_X, \quad Y_1, \dots, Y_n \sim F_Y,$$

con tamaños fijos de $m = 300$ y $n = 400$.

Tradicionalmente, las pruebas no paramétricas de dos muestras se enmarcan en el modelo de localización continuo ($F_Y(x) = F_X(x - \Delta)$), donde se contrasta la hipótesis nula de ausencia de desplazamiento:

$$H_0 : \Delta = 0 \quad \text{vs} \quad H_1 : \Delta \neq 0.$$

Sin embargo, diversos escenarios propuestos en este estudio violan deliberadamente el supuesto de traslación pura (ej. diferencias en forma, asimetría o heterocedasticidad). Por consiguiente, el propósito metodológico no es restringirse a la evaluación de un parámetro de localización idealizado, sino someter los métodos a un escrutinio empírico más amplio bajo la hipótesis nula general de igualdad de distribuciones ($H_0 : F_X = F_Y$). Esto permite cuantificar cómo la forma de las colas, la asimetría o la contaminación por valores atípicos (outliers) afectan tanto el control del error Tipo I como la potencia empírica de cada estadístico.

2.1. Formulación de los Experimentos

El protocolo de simulación Monte Carlo siguió el siguiente procedimiento iterativo para cada uno de los escenarios descritos en la Subsección 2.2:

1. Generar un par de muestras independientes (X, Y) según la parametrización del escenario en curso, garantizando $m = 300$ y $n = 400$.
2. Aplicar de forma simultánea, sobre ese mismo par de muestras, la batería completa de métodos de contraste evaluados: la prueba t de Student, t de Welch, Kolmogorov-Smirnov (KS), Wilcoxon-Mann-Whitney, el intervalo de Hodges-Lehmann y las pruebas condicionales de permutación (medias, medianas y promedios recortados).
3. Computar el estadístico de prueba y el p -valor bilateral asintótico (o exacto, según corresponda) para cada método.

4. Registrar la decisión de rechazo de la hipótesis nula (H_0), aplicando el criterio de decisión establecido en la Subsección 2.3.
5. Almacenar el tiempo de ejecución en milisegundos consumido por cada procedimiento, con el objetivo de perfilar el costo computacional relativo.
6. Iterar los pasos 1 al 5 hasta completar las $R = 500$ realizaciones del escenario. Finalmente, calcular la estimación de la potencia empírica (o la tasa de Error Tipo I) agregando los rechazos observados (ver Subsección 2.4).

Note que (como sugiere el enunciado) se evalúan todos los métodos simultáneamente sobre las mismas muestras generadas en cada iteración (paso 2), lo que suprime la variabilidad inter-simulación, permitiendo una comparación directa y justa del desempeño relativo entre los procedimientos.

2.2. Escenarios y Métodos de Simulación

Para la ejecución de la simulación Monte Carlo se tomaron como base los trece escenarios distribucionales detallados en el enunciado del proyecto, utilizando tamaños muestrales de $m = 300$ y $n = 400$.

Los tres primeros escenarios propuestos permiten estudiar el control del nivel empírico del test bajo casos nulos puros; los escenarios 4 a 6 corresponden a alternativas de desplazamiento estricto entre distribuciones normales; y los escenarios 8 a 13 están diseñados para explorar diferencias distribucionales complejas (formas y colas divergentes).

No obstante, con el fin de evaluar con mayor rigurosidad el comportamiento de los procedimientos en presencia de valores atípicos, el escenario 7 original fue sustituido por dos variantes adicionales (7.1 y 7.2). Como se justificará en la sección de discusión, el escenario original no permite aislar la verdadera sensibilidad perjudicial a los outliers. Los nuevos escenarios son:

7.1 $X \sim N(0, 1)$ vs. $Y \sim N(1, 1)$, sustituyendo 4 puntos de la muestra Y por outliers a la izquierda situados a -100σ de su media. **Evaluación de Potencia:** La hipótesis nula es falsa, pero la magnitud extrema de los outliers empuja artificialmente la media muestral de Y a coincidir con la de X .

7.2 $X \sim N(0, 1)$ vs. $Y \sim N(0, 1)$, sustituyendo 4 puntos de la muestra Y por outliers a la derecha situados a $+10\sigma$ de su media. **Evaluación de Error Tipo I:** La hipótesis nula es verdadera (las poblaciones base son idénticas), pero la contaminación asimétrica puede provocar falsos rechazos en métodos no robustos.

2.3. Nivel de Significancia y Criterio de Decisión

Todos los procedimientos estadísticos se evaluaron calibrados a un nivel de significancia de $\alpha = 0.05$. La regla de decisión se implementó bajo una lógica bilateral:

Procedimientos basados en p -valores: Se rechaza la hipótesis nula si y solo si el p -valor computado resulta estrictamente menor que el umbral de significancia ($p < 0.05$).

Procedimiento basado en Intervalo de Confianza (Hodges-Lehmann): Explotando la dualidad entre pruebas de hipótesis e intervalos de estimación, se rechaza H_0 si el valor nulo de no desplazamiento (0) queda excluido del intervalo de confianza calculado al 95 %.

2.4. Estimación de la Potencia Empírica y Control de Tamaño

Para cada configuración de método y escenario, la capacidad de la prueba se cuantificó estimando la probabilidad de rechazo empírica. Si I_r denota la función indicadora de rechazo en la réplica independiente $r \in \{1, \dots, R\}$, la estimación puntual se define como:

$$\hat{\pi} = \frac{1}{R} \sum_{r=1}^R I_r$$

La interpretación de $\hat{\pi}$ es dual y depende directamente de la naturaleza del escenario subyacente:

En escenarios donde H_0 es falsa, $\hat{\pi}$ estima la **Potencia Empírica** ($1 - \beta$) del test.

En escenarios donde H_0 es verdadera (escenarios 1,2,3 y 7.2), $\hat{\pi}$ estima el **Nivel de Significancia Empírico** (Tasa de Error Tipo I), el cual idealmente debería converger al valor nominal $\alpha = 0.05$.

3. Implementación

En esta sección se describe la traducción del diseño metodológico a una implementación computacional en Python. Para ello se emplearon librerías de cálculo científico como NumPy y SciPy, particularmente a través de funciones del módulo `scipy.stats` descritas en la documentación oficial de SciPy [3]. El código fuente y la reproducibilidad de los experimentos se encuentran disponibles en el repositorio del proyecto: [link](#).

El entorno de trabajo se organizó en módulos para garantizar la eficiencia y escalabilidad de las simulaciones:

- `config.py`: contiene los parámetros globales del experimento, como el nivel de significancia α y el número de remuestreos B para las permutaciones.
- `distribuciones.py`: contiene las rutinas de generación de muestras para los trece escenarios de simulación y sus variantes.
- `metodos_estadisticos.py`: implementa de forma vectorizada y optimizada los contrastes estadísticos evaluados en el estudio.
- Notebooks de Jupyter: separan lógicamente el flujo de trabajo en la generación de muestras, el procesamiento masivo de los estadísticos y la renderización de las gráficas.

Todos los procedimientos de contraste se programaron en el archivo `metodos_estadisticos.py`. Cada función está diseñada para recibir dos arreglos unidimensionales x e y (las realizaciones de las muestras X e Y), y retornar un valor booleano: `True` si se rechaza la hipótesis nula bajo el nivel α , y `False` en caso contrario.

3.1. Pruebas t

Ambas pruebas t descritas anteriormente se implementaron mediante la función `ttest_ind` del módulo `scipy.stats`; véase la documentación oficial de SciPy. El siguiente código corresponde a la versión de Welch:

```
1 def test_t_student(x, y):
2     estadistico, p_val = stats.ttest_ind(x, y, equal_var=False)
3     return p_val < ALPHA
```

Al declarar explícitamente el parámetro `equal_var=False`, el algoritmo ejecuta la versión de Welch de la prueba (con el ajuste de grados de libertad de Welch-Satterthwaite), siendo congruente con la definición teórica de la subsección 1.2. Para la prueba t estándar simplemente se declara el parámetro `equal_var=True`.

Cabe aclarar que la función de la librería devuelve tanto el estadístico t como su p -valor, esto sirvió para verificar que la implementación coincide con la teoría, puesto que hicimos pruebas pequeñas en la que el estadístico y el p -valor puedan calcularse manualmente. De esta forma, se comprobó que la función de la librería produce el resultado esperado antes de utilizarla en los experimentos masivos.

3.2. Prueba de Kolmogorov-Smirnov

El test de Kolmogorov–Smirnov se implementó mediante la función `ks_2samp` de `scipy.stats`; véase la documentación oficial de SciPy. El siguiente código corresponde a la implementación utilizada:

```
1 def test_ks(x, y):
2     estadistico, p_val = stats.ks_2samp(x, y)
3     return p_val < ALPHA
```

Dado que los tamaños muestrales son grandes ($m = 300, n = 400$), la librería calcula el p -valor evaluando directamente el truncamiento de la serie asintótica de la distribución de Kolmogorov, descrita en 1.6. Esto reduce drásticamente el tiempo de obtención del p -valor.

3.3. Estadístico de Wilcoxon-Mann-Whitney

El test de Wilcoxon–Mann–Whitney se implementó mediante la función `mannwhitneyu` del módulo `scipy.stats`; véase la documentación oficial de SciPy. El siguiente código corresponde a la implementación en el proyecto:

```
1 def test_wilcoxon(x, y):
2     estadistico, p_val = stats.mannwhitneyu(x, y, alternative='two-sided')
3     return p_val < ALPHA
```

Debido a que el cálculo combinatorio exacto de la distribución nula de U es computacionalmente prohibitivo para los tamaños muestrales manejados ($m = 300$ y $n = 400$), la librería emplea por defecto la aproximación asintótica sustentada en el Teorema del Límite Central. Bajo la hipótesis nula y suponiendo distribuciones absolutamente continuas (ausencia de empates), los momentos exactos son:

$$\mathbb{E}[U] = \frac{mn}{2} = 60000, \quad \text{Var}(U) = \frac{mn(m+n+1)}{12} = 7010000.$$

Por consiguiente, la transformación lineal:

$$Z = \frac{U - \frac{mn}{2}}{\sqrt{\frac{mn(m+n+1)}{12}}} \approx \frac{U - 60000}{2647.64}$$

es aproximadamente normal estándar cuando m y n son grandes.

Como en este trabajo se emplearon tamaños $m = 300$ y $n = 400$, esta aproximación es razonable tanto desde el punto de vista teórico como computacional. Para respaldar visualmente esta justificación, en la figura 1 se muestra un QQ-plot del estadístico estandarizado frente a la distribución normal estándar bajo simulaciones en el caso nulo. Si los puntos del gráfico se alinean de manera aproximada con la recta de referencia, ello constituye evidencia empírica de que la aproximación normal es adecuada.

Las ligeras desviaciones al principio y al final del QQ-plot obedecen a que Z tiene colas ligeramente más pesadas que la de su aproximación normal. No obstante, dado que en la región crítica de rechazo ($|Z| \approx 1.96$) la alineación empírica es exacta, estas discrepancias marginales no comprometen el cálculo del p -valor en nuestro caso.




Figura 1: QQ-plot del estadístico U estandarizado vs $N(0, 1)$

3.4. Intervalo de confianza Hodges-Lehmann (HL)

El procedimiento basado en Hodges–Lehmann se implementó con operaciones la librería NumPy de manera manual tal como se formuló en la Subsección 1.4, con cuantiles de la distribución normal estándar obtenidos desde `scipy.stats`; véase la documentación oficial de SciPy para la función de cuantiles.

```

1 def test_hodges_lehmann(x, y):
2     m, n, mn, mean_u = len(x), len(y), m * n, mn / 2
3     std_u = np.sqrt(mn * (m + n + 1) / 12)
4     z_alpha = stats.norm.ppf(1 - ALPHA / 2)
5
6     lower_idx = max(0, int(np.round(mean_u - z_alpha * std_u)) - 1)
7     upper_idx = min(mn - 1, int(np.round(mean_u + z_alpha * std_u)) - 1)
8
9     diffs = (y[:, None] - x).flatten()
10    partitioned = np.partition(diffs, [lower_idx, upper_idx])
11    ci_lower, ci_upper = partitioned[lower_idx], partitioned[upper_idx]
12
13    return not (ci_lower <= 0 <= ci_upper)

```

Desde una perspectiva algorítmica, el uso de `np.partition` es un acierto. En lugar de ejecutar un ordenamiento total $\mathcal{O}(N \log N)$ de las $mn = 120,000$ diferencias, `np.partition` emplea un algoritmo de selección que localiza los cuantiles requeridos en tiempo esperado $\mathcal{O}(N)$. Esto reduce un poco el costo computacional al iterar el procedimiento en el ciclo de Monte Carlo.

3.5. Test condicional de permutación

Los tests de permutación se implementaron mediante la función `permutation_test` del módulo `scipy.stats`; véase la documentación oficial de SciPy. Se evaluaron tres estadísticos de contraste (media, mediana y media recortada). El siguiente código corresponde a la implementación utilizada:

```
1 def test_permutacion(x, y, estadistico='media'):
2     def diff_medias(a, b, axis=0):
3         return np.mean(a, axis=axis) - np.mean(b, axis=axis)
4
5     def diff_medianas(a, b, axis=0):
6         return np.median(a, axis=axis) - np.median(b, axis=axis)
7
8     def diff_trim(a, b, axis=0):
9         return stats.trim_mean(a, 0.1, axis=axis) - stats.trim_mean(b, 0.1, axis=axis)
10
11     if estadistico == 'media':
12         stat_func = diff_medias
13     elif estadistico == 'mediana':
14         stat_func = diff_medianas
15     else: stat_func = diff_trim
16
17     res = stats.permutation_test((x, y), stat_func,
18                                 permutation_type='independent',
19                                 n_resamples=PERMUTATIONS,
20                                 alternative='two-sided',
21                                 vectorized=True)
22     return res.pvalue < ALPHA
```

El argumento `vectorized=True` es fundamental en esta rutina, ya que permite vectorizar el cálculo del estadístico sobre la matriz entera de permutaciones simultáneas, mitigando en parte el severo cuello de botella que representa este método frente a los asintóticos.

3.6. Verificación empírica en casos de prueba

Previo a la ejecución de las simulaciones masivas (Monte Carlo de $R = 500$), se desarrolló un entorno de pruebas unitarias detallado (Link archivo). El propósito de este módulo fue aislar la lógica de cada función y verificar su convergencia matemática frente a cálculos manuales o implementaciones de referencia.

En la prueba de Welch se comparó el estadístico y el p -valor devueltos por la librería con el cálculo manual. Para Wilcoxon–Mann–Whitney se verificó el conteo exacto de comparaciones pareadas y su concordancia con el estadístico U . En el caso de Hodges–Lehmann se comprobó explícitamente la construcción del conjunto de diferencias $Y_j - X_i$, la correcta indexación de las fronteras asintóticas y la regla de rechazo basada en la inclusión o no inclusión del valor 0. Finalmente, para los tests de permutación se contrastó el resultado con ejemplos pequeños enumerables.

Estas verificaciones permiten asegurar que el código implementa correctamente las definiciones teóricas antes de utilizar los procedimientos en los experimentos de Monte Carlo.

4. Resultados

4.1. Control del Error Tipo I

En la Figura 2 se presentan las tasas empíricas de rechazo obtenidas bajo los escenarios donde la hipótesis nula es verdadera. Dado que el nivel de significancia fijado es $\alpha = 0.05$ y el número de simulaciones es $R = 500$, el número de falsos rechazos observados sigue teóricamente una distribución $\text{Bin}(500, 0.05)$. Por consiguiente, la tasa de error Tipo I estimada ($\hat{\alpha}$) tiene una desviación estándar (error estándar) dada por:

$$\sigma_{\hat{\alpha}} = \frac{\sqrt{R\alpha(1-\alpha)}}{R} = \frac{\sqrt{500 \cdot 0.05 \cdot 0.95}}{500} \approx 0.00975 \quad (0.975 \%)$$

Para los escenarios estándar sin contaminación (1.0, 2.0 y 3.0), todos los métodos logran preservar el tamaño de la prueba, manteniendo sus tasas de rechazo dentro del margen de fluctuación estocástica esperada (aproximadamente en el rango $[4.0\%, 6.8\%]$). No obstante, la robustez se quiebra en el escenario 7.2 (presencia de outliers asimétricos): se observan inflaciones severas del error Tipo I, alcanzando un 13.6% para la prueba t clásica, 18.2% para la prueba de Welch y 14.6% para la permutación de medias. En agudo contraste, el test KS y Wilcoxon absorben eficazmente el impacto de los valores atípicos, registrando tasas controladas del 5.8% y 6.4%, respectivamente.




Figura 2: Tasa empírica de Error Tipo I estimada por escenario y método. Las líneas de referencia ilustran la banda de fluctuación esperada (dependiente de $\sigma_{\hat{\alpha}}$) bajo la distribución binomial de la simulación.

4.2. Potencia Empírica

La Figura 3 muestra el poder estadístico (tasa de rechazo bajo H_1) de los distintos métodos. El escenario 7.1 pone en evidencia la fragilidad extrema de las pruebas basadas en momentos: ante outliers que enmascaran la diferencia real de las medias poblacionales, las pruebas t , Welch y la permutación de medias sufren

un colapso absoluto, obteniendo una potencia nula (0.0 %). Mientras tanto, Kolmogorov-Smirnov, Wilcoxon, Hodges-Lehmann y las permutaciones robustas (mediana y media recortada) logran una potencia del 100 %. Por otro lado, al evaluar diferencias estructurales complejas más allá de desplazamientos puros (escenarios 11 a 13), se constata la miopía de los métodos de permutación. En el escenario 11, las pruebas de permutación de medias y promedios recortados ven su potencia desplomarse hasta el 5.6 %. Simultáneamente, las pruebas verdaderamente libres de distribución como Wilcoxon y Hodges-Lehmann mantienen una potencia superior al 74 % en todos estos casos, demostrando mayor sensibilidad ante asimetrías y diferencias en las colas.



Figura 3: Potencia empírica observada en los distintos escenarios bajo hipótesis alternativa.

Por último, note que en el escenario 7, todas las pruebas tienen potencia del 100 %, es decir, los outliers no lograron confundir a ningún procedimiento, ni siquiera a los basados en la distribución t . Por esta razón se planteó el escenario 7.1.

4.3. Tiempos de Ejecución

Los tiempos promedio de procesamiento por simulación se detallan en la Figura 4. Los métodos analíticos y asintóticos (t -Student, Welch, Wilcoxon estandarizado y KS) presentan tiempos de ejecución virtualmente instantáneos, cercanos a 0 segundos por iteración. En contrapartida, los métodos basados en remuestreo exigen un peaje computacional considerable: 0.07s para `perm_media`, 0.09s para `perm_mediana` y 0.10s para `perm_trim`, evidenciando la ineficiencia de recalculer el estadístico miles de veces en cada ciclo de Monte Carlo.




Figura 4: Comparativa de tiempos de ejecución promedio por método y simulación.

5. Discusión

5.1. ¿Cuáles métodos se ven menos afectados por outliers?

Para evaluar la robustez de los métodos estadísticos frente a valores atípicos, es necesario analizar tanto la inflación del error Tipo I como la pérdida de potencia (aumento del error Tipo II).

En primer lugar, cabe destacar que el escenario 7 original del enunciado ($X \sim N(0, 1)$ vs $Y \sim N(1, 1)$ con outliers a la derecha en Y) carece de utilidad práctica para este propósito. Dado que en el escenario 6 (sin outliers) las pruebas ya alcanzan una potencia del 100 %, añadir valores extremos en la dirección del desplazamiento real únicamente incrementa la magnitud del estadístico de prueba, haciendo que el rechazo sea aún más trivial. Por ello, el análisis recae en los escenarios propuestos 7.1 y 7.2.

Control del Error Tipo I (Escenario 7.2): En este escenario, la hipótesis nula teórica es verdadera ($X, Y \sim N(0, 1)$), pero se introducen outliers a la derecha en Y . Los resultados demuestran que las pruebas paramétricas (prueba t de Student y Welch) y la prueba de permutación de la media son altamente vulnerables, presentando una tasa inaceptable de falsos positivos (error Tipo I inflado). Por el contrario, la permutación con medias recortadas (trimmed) muestra mayor robustez frente a la distorsión de la media. Las pruebas basadas en rangos (Wilcoxon y Hodges-Lehmann) resultan ligeramente liberales en presencia de estos valores extremos, pero mantienen el error Tipo I en márgenes estadísticamente aceptables. Por último, la prueba KS demuestra una robustez superior, pues es la única prueba que registra un error de tipo I a menos de una desviación estándar del valor esperado 0.05.

Preservación de la Potencia (Escenario 7.1): En este caso, la hipótesis nula es falsa ($X \sim N(0, 1)$ vs $Y \sim N(1, 1)$), pero los outliers extremos a la izquierda en Y fuerzan a que las medias muestrales de ambos grupos coincidan. Ante esta contaminación, las pruebas dependientes de la media muestral (t -Student, Welch

y permutación de medias) pierden toda su potencia, fracasando en detectar la diferencia real entre las distribuciones. En contraste, el test de Kolmogorov-Smirnov (KS), Wilcoxon y Hodges-Lehmann exhiben robustez, manteniendo una potencia del 100 %. Las permutaciones de la mediana y de medias recortadas también logran aislar el efecto del outlier, demostrando ser fuertemente robustas en la protección de la potencia.

5.2. ¿Cuáles métodos detectan mejor diferencias distribucionales más allá de la media?

El análisis se centra en los escenarios 8 a 13, cuyas densidades teóricas se pueden observar en la Figura 5. Es claro que las densidades tienen formas, colas y soportes distintos, pero las medias pueden ser cercanas.

Superioridad de las pruebas globales y de rangos: Nuevamente, el vencedor indiscutible en este bloque analítico es el test de **Kolmogorov-Smirnov (KS)**. Al evaluar la distancia máxima entre las distribuciones empíricas acumuladas (norma del supremo), el KS logra capturar variaciones en la dispersión, el sesgo y la forma de las colas, manteniendo una potencia sobresaliente en la mayoría de los casos. En un segundo lugar, con desempeño casi idéntico y plenamente aceptable, se encuentran **Wilcoxon** y **Hodges-Lehmann**. Al basarse en el ordenamiento de rangos combinados, estos métodos logran una excelente sensibilidad ante diferencias estructurales generales sin depender de un único momento poblacional.

Por otro lado, una lectura superficial de la tabla de potencias estimadas sugiere que las pruebas de permutación basadas en la mediana y en medias recortadas tienen un desempeño aceptable para distinguir distribuciones. Sin embargo, no detectan realmente las sutilezas morfológicas de la distribución completa, sino que se limitan a evaluar la convergencia de su parámetro objetivo específico.

Para ilustrar esto, observe que en el **Escenario 10**, la prueba de permutación de la mediana tiene alta potencia. No obstante, al revisar las densidades (Figura 5), es evidente que esto ocurre porque, por mera casualidad de los parámetros, las medianas teóricas de la Gamma y la Pareto (líneas sólidas) se encuentran significativamente distanciadas. Mientras que, al analizar el **Escenario 11**, donde las distribuciones siguen siendo estructuralmente distintas, las medianas teóricas resultan estar sumamente cerca. Como consecuencia directa, esta prueba pierde drásticamente su potencia (cayendo al 33.6 %).




Figura 5: Comparación de densidades teóricas para los escenarios 8 a 13. Las líneas verticales punteadas representan la media poblacional (esperanza) de cada distribución, mientras que las líneas verticales continuas (sólidas) indican la posición exacta de las medianas.

5.3. ¿Cómo se comparan los costos computacionales?

Como se evidenció en la Figura 4 de la sección de resultados, existe una disparidad monumental en la eficiencia computacional de los métodos evaluados. Las pruebas analíticas (t -Student, Welch, Kolmogorov-Smirnov) y los métodos basados en rangos (Wilcoxon, Hodges-Lehmann) se ejecutan de manera casi instantánea, con tiempos promedios cercanos a 0 segundos por simulación.

En radical contraste, los métodos basados en remuestreo (`perm_media`, `perm_mediana`, `perm_trim`) exigen un esfuerzo computacional órdenes de magnitud mayor, tardando entre 0.07 y 0.11 segundos por simulación. Esta asimetría es una consecuencia directa de la naturaleza del algoritmo, el cual requiere reordenar y recalculer el estadístico de prueba miles de veces por cada iteración del ciclo de Monte Carlo.

6. Conclusiones

Evaluando el desempeño integral, el test de **Kolmogorov-Smirnov (KS)** se posiciona como el método más robusto frente a valores atípicos, controlando rigurosamente el error Tipo I y maximizando la potencia, seguido muy de cerca por **Wilcoxon** y **Hodges-Lehmann**, cuyos comportamientos son casi equivalentes. En un segundo escalón se ubican las pruebas de permutación de la mediana y medias recortadas; si bien son excelentes preservando la potencia (robustez ante error Tipo II) y tuvieron potencia de 100 en los escenarios de diferencia en localización, en los escenarios con diferencias en la estructura de las densidades registraron una potencia considerablemente menor que la prueba KS.

En este contexto de detectar diferencias estructurales en las distribuciones, si bien es cierto que las pruebas de permutación robustas (mediana y recortada) son capaces de detectar desviaciones más allá de una simple diferencia en la media poblacional (superando a la prueba t), su éxito es puramente circunstancial. Fracasan sistemáticamente al intentar capturar discrepancias sutiles en la estructura de la distribución, ya que su capacidad de rechazo está subordinada de manera exclusiva a la separación fortuita del estadístico central particular que intentan medir.

Finalmente, considerando los hallazgos de las subsecciones anteriores, donde métodos rápidos como el test KS y Wilcoxon demostraron una robustez y potencia superiores o equivalentes, el uso de pruebas de permutación resulta ineficiente para estos escenarios. El abrumador costo computacional adicional que demandan no se traduce en ninguna ganancia de poder estadístico o robustez práctica.

Por lo tanto, dentro de los métodos iniciales del enunciado, consideramos el preferible sería Wilcoxon o Hodges-Lehmann, puesto que mantiene tasas de error de tipo I y potencias aceptables, al tiempo que su costo computacional es mínimo (usando la versión aproximada de Wilcoxon) y son sencillos de implementar.

Adicionalmente, se quiso comparar estos procedimientos con una prueba Kolmogorov-Smirnov, y esta resultó ser una brutal vencedora en todos los apartados, ¡viva Kolmogorov!.

Referencias

- [1] Prueba t de welch — Wikipedia, la enciclopedia libre, 2026. [En línea; consultado el 24-marzo-2026].
- [2] Ronald H Randles and Douglas A Wolfe. *Introduction to the Theory of Nonparametric Statistics*. John Wiley & Sons, New York, 1979.
- [3] SciPy Community. *SciPy v1.17.0 Manual*. SciPy, 2025. Documentation for the SciPy scientific computing library.
- [4] Robert J. Serfling. *Approximation Theorems of Mathematical Statistics*. Wiley series in probability and mathematical statistics : Probability and mathematical statistics. Wiley, Hoboken, New Jersey, 1980.
- [5] Jun Shao. *Mathematical Statistics*. Springer Science & Business Media, New York, 2nd edition, 2003. Sección 6.5.2, p. 448.
- [6] Dennis W Wackerly, William Mendenhall, and Richard L Scheaffer. *Mathematical Statistics with Applications*. Cengage Learning, Belmont, CA, 7th edition, 2008.
- [7] Bernard L Welch. The generalization of ‘student’s’ problem when several different population variances are involved. *Biometrika*, 34(1/2):28–35, 1947.